


Isolation Forest

Pontos incomuns.
Caminhos mais curtos.

TEORIA + PYTHON

FÁCIL DE ISOLAR



Thiago Martins · Gabriel da Silva · Kauan Fonseca
João Pedro Carvalho · João Gabriel

Do problema à investigação

Uma técnica simples exige preparação dos dados e interpretação do contexto.

01

O problema

O que torna uma compra incomum?

02

A técnica

Definição, motivação e histórico.

03

O mecanismo

Cortes aleatórios e pontuação.

04

Na prática

Aplicações, limites e caso CERN.

05

Nosso estudo

CSV, Python, gráficos e resultados.

06

O aprendizado

O que detectar — e o que investigar.

Raro não significa errado

Uma observação incomum pode ser fraude, erro ou uma compra legítima.

01

Poucos exemplos

Nem sempre há rótulos confiáveis.

02

Múltiplos atributos

O desvio pode aparecer apenas na combinação.

03

Contexto importa

O alerta inicia a investigação; não comprova fraude.

EXEMPLO DA LOJA

R\$ 1.100 pode ser comum em eletrônicos.
Por um item de papelaria, exige atenção.

A pergunta é: quanto fácil é isolar?

Isolation Forest é um algoritmo não supervisionado de detecção de anomalias baseado em árvores aleatórias.

SEM RÓTULOS

Não supervisionado

Não exige exemplos confirmados de fraude ou falha.

SEM DISTÂNCIAS

Cortes aleatórios

Particiona os dados até separar observações.

COM PONTUAÇÃO

Grau de raridade

Mede o comprimento médio dos caminhos na floresta.

Isolar o raro pode exigir menos esforço

Modelar o comum

Métodos estatísticos, de distância ou densidade procuram desvios do padrão. O custo depende da técnica e da implementação.

Isolar o incomum

Pontos raros e diferentes tendem a se separar em poucos cortes. Pequenas subamostras tornam o treino eficiente.

Com árvores e subamostra fixas, o custo cresce aproximadamente com o tamanho da base.

De artigo acadêmico a ferramenta cotidiana

2008

Proposta original

Liu, Ting e Zhou apresentam Isolation Forest na ICDM.

2012

Análise ampliada

Artigo no ACM TKDD consolida o método e os experimentos.

2016

scikit-learn

IsolationForest entra na versão 0.18 da biblioteca.


2018+

Novas variantes

Extended Isolation Forest amplia as direções dos cortes.

Menos cortes. Maior suspeita.

Ilustração conceitual: uma árvore separa pontos por cortes aleatórios.



- 01 Subamostra**
Seleciona registros para uma árvore.
- 02 Partição**
Sorteia atributo e valor de corte.
- 03 Floresta**
Repete e calcula o caminho médio.

Na implementação, há limite de profundidade e correção para folhas com vários pontos.

A teoria e o código usam convenções diferentes

NO ARTIGO ORIGINAL

$$s(x, n) = 2^{(-E[h(x)] / c(n))}$$

$E[h(x)]$: comprimento médio do caminho.
 $c(n)$: normalização pela subamostra.

Maior score → mais anômalo

NO SCIKIT-LEARN

**decision_function =
score_samples – offset_**

Score negativo → candidata
Score ≥ 0 → não sinalizada

Score não é probabilidade de fraude.

Poucas linhas depois de preparar os dados



```
from sklearn.ensemble import IsolationForest

modelo = IsolationForest(
    n_estimators=100,
    contamination=0.05,
    random_state=42)

modelo.fit(X)
df["score"] = modelo.decision_function(X)
df["rotulo"] = modelo.predict(X)
```

100

Árvores

Mais árvores reduzem a variabilidade.

5%

Triagem

Fração definida antes da avaliação.

-1

Alerta

Rótulo de candidata a anomalia.

Uma técnica, vários contextos

O ponto comum: encontrar observações que se afastam do comportamento usual.

01

Finanças

Transações incomuns para triagem e revisão.

02

Segurança

Tráfego e acessos fora do padrão.

03

Indústria

Leituras atípicas de sensores e equipamentos.

04

Saúde

Exames ou registros que merecem conferência.

05

Varejo e logística

Compras, atrasos e consumo inesperados.

06

Qualidade de dados

Identificação de possíveis erros de registro.

O alerta precisa de contexto

01 Cortes alinhados aos eixos

Podem distorcer a pontuação em dados correlacionados.

02 Anomalias locais

Um caso incomum dentro de um grupo pode passar despercebido.

03 Preparação dos dados

Categorias exigem codificação; ausências precisam de tratamento.

04 Limiar e interpretação

A fração de alertas afeta o trabalho de investigação. O score não explica a causa.

CERN: detectar servidores anômalos

Uma aplicação operacional em infraestrutura de nuvem, descrita por Metaj (2022).

~14 mil

máquinas virtuais no contexto do estudo

AUC-ROC > 0,95

para cada um dos três modelos
na avaliação relatada pela tese

Pipeline de monitoramento

Isolation Forest +
LSTM-AutoEncoder +
GRU-AutoEncoder

Um ensemble prioriza diariamente os
servidores mais incomuns para os gestores.

O resultado é específico do estudo; não garante
desempenho na nossa base.

Mais contexto para o isolamento

01	Extended e Deep IF	Cortes em outras direções e novas representações dos dados.
02	Dados em fluxo	Adaptações para monitoramento e atualização contínua.
03	Explicabilidade	Métodos de atribuição ajudam a examinar os atributos do alerta.
04	Sistemas híbridos	Combinação com outros modelos e etapas de investigação.

Uma loja fictícia. Um problema realista.

Transações de setembro de 2026; o gabarito é usado apenas na avaliação.

126

TRANSAÇÕES

6

CASOS DOCUMENTADOS

4

CÉLULAS AUSENTES

Identificação	id_transacao · data_hora
Numéricos	valor · quantidade · desconto_percentual
Categorias	categoria · pais · pagamento

Casos plantados: 3 extremos + 2 combinações de preço e categoria + 1 indevida sem desvio observável.

O trabalho começa antes do fit

01

Inspecionar

Tipos, ausências e estatísticas.

02

Tratar

Mediana por categoria; moda nos categóricos.

03

Criar atributos

Hora cíclica, preço por item e razão por categoria.

04

Codificar

One-hot encoding de categoria, país e pagamento.

05

Aplicar o modelo


100 árvores · 5% · semente 42.

06

Avaliar

Três gráficos e comparação com o gabarito.

4 de 5 anomalias observáveis foram encontradas




7

compras sinalizadas
para investigação

3 falsos positivos

Precisão: 57,1%
Recall: 80,0%
1 anomalia não detectada

Mais alertas não garantem mais acertos



Sensibilidade do limiar

Fração	Alertas	Acertos
3%	4	3
5%	7	4
8%	10	4
10%	13	4

À esquerda do zero: candidatas a anomalia.
A fração define o corte; não é probabilidade de fraude.

O modelo encontra padrões, não intenções

4

ENCONTRADAS

T121 · valor de R\$ 8.000
T122 · quantidade de 45 itens
T123 · desconto de 95%
T124 · preço incompatível com a categoria

2

SEM ALERTA

T125 · eletrônicos baratos demais
T126 · indevida sem desvio observável (fora do recall)

3

FALSOS POSITIVOS

T049 · T058 · T088
Compras legítimas em PT, com combinações relativamente raras.

Investigar produto, promoção e contexto antes de bloquear uma compra ou remover um registro.

Fontes que sustentam o trabalho

01 Isolation Forest

Liu, Ting e Zhou · ICDM, 2008

03 IsolationForest: API oficial

scikit-learn · parâmetros, scores e implementação

05 Extended Isolation Forest

Hariri, Kind e Brunner · arXiv:1811.02141

02 Isolation-Based Anomaly Detection

Liu, Ting e Zhou · ACM TKDD, 2012

04 CERN OpenStack: estudo de caso

Stiven Metaj · CERN-THESIS-2022-049, 2022

06 Deep Isolation Forest

Xu et al. · arXiv:2206.06602

Os títulos são links clicáveis. URLs completas também estão nas notas do slide e no README.

Encontrar o incomum é o início da investigação.

126

TRANSAÇÕES

4 / 5

ANOMALIAS ENCONTRADAS

3

FALSOS POSITIVOS

Preparar os dados. Calibrar o limiar. Entender o contexto.